

Génération de musique conditionnée par l'émotion

EXPLORATION DES ARCHITECTURES VAE POUR LA MUSIQUE ÉMOTIONNELLE

Léa YANG et Eric CHEN

PROJET DEEP LEARNING

--- Plan

1

Introduction

2

Les données

3

L'approche VAE

4

**Test 1 — VAE
avec MLP**

5

**Test 2 — VAE
avec CNN**

6

**Test 3 — VAE
avec LSTM**

7

**Le C-VAE : la
solution
conditionnelle**

8

**Résultats et
validation**

9


Conclusion

— Introduction

- ① La musique transmet naturellement des émotions : joie, tristesse, tension, calme.
- ② Peut-on entraîner une IA à générer une musique correspondant à une émotion précise ?
- ③ **Objectif :**
Développer un système de génération musicale émotionnelle basé sur plusieurs architectures de VAE.

Les données : dataset EMOPIA

Quadrant	Basse Valence	Haute Valence
Haute Activation (Arousal)	Q2 : Colère, tension	Q1 : Joie, excitation
Basse Activation (Arousal)	Q3 : Tristesse, dépression	Q4 : Calme, tendresse



Les quatre quadrants du modèle circomplexe de Russell.

Tokenisation – REMI


- 1.Bar : Indique le début d'une nouvelle mesure.
- 2.Position : Divise la mesure en une grille (ex : 16 ou 32 subdivisions). Cela indique quand la note est jouée.
- 3.Pitch : La hauteur de la note (0 à 127 en MIDI).
- 4.Velocity : La force de frappe (quantifiée ici sur 16 niveaux pour simplifier l'apprentissage).
- 5.Duration : La durée de la note (exprimée en fractions de pulsation).

UNE NOTE = [BAR_0] → [POSITION_0] → [PITCH_60] → [VELOCITY_12] → [DURATION_2.0] → [POSITION_8] → ...


Vocabulaire final : 268 tokens

longueur de séquence : 512 (en rouge)

- troncature
- padding




Visualisation des données brutes




→ points superposés

VAE MLP (Multiple Layer Perceptron)




- 87 millions de paramètres
- Overfitting
- Résultat peu satisfaisant (*écoute du sample)

VAE CNN (Convolutional Neural Network)





- 539 000 de paramètres
- Pas d'overfitting
- Début de patterne mais pas de cohérence globale (*écoute du sample)

VAE LSTM (Long Short-Term Memory)




- 3,245,132 de paramètres
- Pas d'overfitting
- Loss totale d'entraînement la plus basse à 1285.8
- Cohérence musicale et distinction des émotions (*écoute du sample)


Espaces latents



C-VAE LSTM




CVAE





LSTM bidirectionnel

C-VAE LSTM



- quasiment comme VAE LSTM
- early stopping
- loss finale : 1180

Espaces latents et résultats



→ 4 clusters qui correspondent aux cadrants de Russell

Pour aller plus loin

- **Augmentation de données : Décaler automatiquement les morceaux du dataset dans les 12 tonalités possibles.**
- **Remplacer le framework VAE/LSTM par un modèle de type Transformer**
 - > **Mémoire globale**
 - > **Maîtrise totale de la syntaxe musicale**
- **Evolution vers le multi-instrument : générer un vrai orchestre musical**

MERCI

POUR VOTRE ATTENTION